

# Анализ робастности неявного градиентного спуска в архитектуре Transformer к выбросам (Outliers)

Владимир Назаров  
nazarov.vr@phystech.edu

Игнат Чернышов  
chernyshov.im@phystech.edu

Марк Захаров  
zakharov.mark@phystech.edu

Максим Савичев  
savichev.mv@phystech.edu

April 15, 2026

В статье [1] показано, что прямой проход трансформера способен аппроксимировать шаги градиентного спуска (GD). В данном проекте предлагается исследовать способность этой архитектуры к выучиванию алгоритмов робастной оптимизации. Цель исследования — проверить, как наличие экстремальных выбросов (outliers) в контексте влияет на предсказания модели и способна ли она научиться игнорировать эти аномалии. В ходе работы мы планируем последовательно изучить различные варианты архитектуры трансформера — от простейшего механизма линейного внимания до моделей с нелинейностями — чтобы выяснить, при каких условиях сеть может превзойти стандартный аналитический метод наименьших квадратов (MSE), уязвимый к зашумленным данным.

## 1 Идея

Проект является исследовательским расширением базовой статьи «Transformers learn in-context by gradient descent» [1]. В оригинальной работе, а также в смежных фундаментальных исследованиях In-Context Learning для линейных моделей [2, 3], модель симулировала шаги градиентного спуска для классической задачи линейной регрессии с минимизацией среднеквадратичной ошибки (MSE):

$$\min_{\theta} \frac{1}{n} \sum_{i=1}^n (x_i^T \theta - y_i)^2.$$

Однако классический градиентный спуск в такой постановке имеет известный математический недостаток: он крайне чувствителен к выбросам. Основная идея нашего проекта заключается в проверке того, наследует ли трансформер эту уязвимость

алгоритма, который он аппроксимирует, или же способен в процессе мета-обучения выработать более устойчивую (робастную) стратегию.

Для реализации задуманного мы модифицируем пайплайн генерации синтетических данных для линейной регрессии [2]. Обучающая выборка (контекст) будет генерироваться по следующему правилу:

$$y_i = x_i^T \theta^* + \varepsilon_i + \eta_i,$$

где  $\theta^*$  — истинные веса модели,  $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$  — стандартный гауссовский шум. Переменная  $\eta_i$  моделирует аномальные значения и искусственно внедряется с вероятностью  $p \in [0.05, 0.10]$  (в этом случае значение  $|\eta_i|$  выбирается достаточно большим). При этом «правильным» ответом (target), который модель должна предсказать для тестовой точки  $x_{\text{test}}$ , будет истинное значение без учета этого шума:  $y_{\text{test}} = x_{\text{test}}^T \theta^*$ .

Эксперименты будут проводиться итеративно: мы начнем с простейшей архитектуры (только линейное внимание, как в начале оригинальной статьи) и затем перейдем к тестированию моделей с добавлением Softmax и MLP-слоев. Мы хотим исследовать, на каком этапе архитектурной сложности модель обретает способность фильтровать аномалии в контексте. Итоговым результатом станет сравнительный анализ траекторий предсказаний трансформера, стандартного GD и аналитических методов робастной оптимизации [4], минимизирующих, например, функцию потерь Хьюбера (Huber Loss):

$$\min_{\theta} \frac{1}{n} \sum_{i=1}^n H_{\delta}(x_i^T \theta - y_i), \quad \text{где} \quad H_{\delta}(a) = \begin{cases} \frac{1}{2}a^2, & \text{если } |a| \leq \delta, \\ \delta(|a| - \frac{1}{2}\delta), & \text{иначе.} \end{cases}$$

Это позволит сделать объективный вывод о границах применимости неявных оптимизаторов внутри In-Context Learning: ограничены ли они строгим копированием базового MSE, или способны гибко адаптироваться под сложную структуру данных.

## Список литературы

- [1] von Oswald, J., Niklasson, E., Randazzo, E., Sacramento, J., Mordvintsev, A., Zhmoginov, A., & Vladymyrov, M. (2023). Transformers learn in-context by gradient descent. *International Conference on Machine Learning (ICML)*, PMLR.
- [2] Garg, S., Tsipras, D., Liang, P. S., & Valiant, G. (2022). What can transformers learn in-context? A case study of linear models. *Advances in Neural Information Processing Systems (NeurIPS)*, 35, 30475-30487.
- [3] Akyürek, E., Schuurmans, D., Andreas, J., Ma, T., & Zhou, D. (2023). What learning algorithm is in-context learning? Investigations with linear models. *International Conference on Learning Representations (ICLR)*.
- [4] Huber, P. J. (1964). Robust estimation of a location parameter. *The Annals of Mathematical Statistics*, 35(1), 73-101.